

Embodied Robot Intelligence

Edition 1.1 Revision Supplement

Volumes I-III 本科补课与全文审读修订桥

Numerical Linear Algebra · Probability · Dynamics · Contact · Generative
Policies

2026-09-10

为什么要加这份修订桥

重新逐页检查前三卷后，一个明显问题是：内容方向正确，但一些章节仍然把“研究者知道的中间台阶”压得过短。对已经学过相关课程的人，它们像提醒；对本科生第一次学习，它们可能变成跳步。

因此前三卷应视为 **Edition 1 Draft**，这份 supplement 先补最影响后续理解的缺口。后续重排 1.1 时，这些内容应该被拆回对应章节，而不是永久留在附录。

Audit 结构审读结论

Volume I 相对最稳，但仍需补：QR/normal equations 的数值差别、Taylor 近似余项直觉、conditional Gaussian 的具体算例、Allan variance 的最小推导。

Volume II 的主要问题不是知识缺失，而是过密：RNEA/ABA/CRBA、contact complementarity、operational-space inertia、Riccati/MPC、observability 都需要更多数值小例子。

Volume III 最需要扩：force closure 的具体几何例子、visual servo 数值例子、BC compounding error、DDPM posterior/ELBO、Flow Matching continuity/transport 的推导链。

目录

为什么要加这份修订桥	ii
第一章 Volume I 补课桥：数值线性代数、Taylor、Gaussian 与 Allan Variance	1
1.1 为什么 normal equations 会把 condition number 平方	1
1.2 QR 为什么更稳	1
1.3 Taylor expansion 不是“把高阶项删掉”	2
1.4 Conditional Gaussian 具体怎么算	2
1.5 Scalar Kalman filter 一次完整数字算例	3
1.6 Allan variance：为什么传感器 noise 不能只报一个标准差	4
第二章 Volume II 补课桥：递归动力学、Contact Complementarity、Operational Inertia 与 Riccati	5
2.1 RNEA 不应该只记成一个函数名	5
2.2 ABA 与“先算完整 M^{-1} ”的区别	6
2.3 一个 1D unilateral contact 的 complementarity 数字例子	6
2.4 Operational inertia 的一维例子	7
2.5 Riccati recursion 从 finite-horizon dynamic programming 推	7
第三章 Volume III 补课桥：Force Closure、BC Distribution Shift、DDPM Posterior 与 Flow Transport	9
3.1 2D force closure 的一个可画出来例子	9
3.2 一个简单 LP 形式	9
3.3 BC compounding error 的两步 toy example	10
3.4 DDPM posterior 为什么仍是 Gaussian	11
3.5 DDPM ELBO 与 simplified noise loss 的关系	11
3.6 Flow Matching continuity equation 从守恒直觉来	12
3.7 为什么 linear CFM target 是 $x_1 - x_0$	12

第四章 全文继续修订时必须遵守的写作规则	14
----------------------	----

第一章 Volume I 补课桥：数值线性代数、Taylor、Gaussian 与 Allan Variance

1.1 为什么 normal equations 会把 condition number 平方

Least squares:

$$\min_x \|Ax - b\|_2^2.$$

正规方程:

$$A^\top Ax = A^\top b.$$

若 singular values:

$$\sigma_1 \geq \cdots \geq \sigma_r > 0,$$

则 $A^\top A$ 的非零 eigenvalues:

$$\sigma_i^2.$$

因此:

$$\kappa_2(A^\top A) = \kappa_2(A)^2.$$

数值例子:

$$\kappa(A) = 10^6 \Rightarrow \kappa(A^\top A) = 10^{12}.$$

Double precision machine epsilon 约:

$$2.2 \times 10^{-16}.$$

粗略有效数字损失会非常明显。

所以:

$$(A^\top A)^{-1} A^\top b$$

适合推导, 不是首选 production implementation。

1.2 QR 为什么更稳

若:

$$A = QR,$$

$Q^\top Q = I$, R upper triangular.

Least squares:

$$\|Ax - b\| = \|QRx - b\|.$$

左乘 $Q^\top$ 不改变 2-norm:

$$\|Rx - Q^\top b\|.$$

Full column rank 时解:

$$Rx = Q^\top b.$$

只需要 triangular solve, 不形成 $A^\top A$ 。

SVD 更稳、可处理 rank deficiency, 但通常更贵。

本科生应形成:

$$\text{solve/QR/SVD 优先于 explicit inverse.}$$

1.3 Taylor expansion 不是“把高阶项删掉”

一维:

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + \frac{1}{2}f''(\xi)\Delta x^2$$

for some ξ between x and $x + \Delta x$ 。

所以一阶近似误差:

$$O(\Delta x^2).$$

多维:

$$f(x + \delta) = f(x) + J(x)\delta + O(\|\delta\|^2).$$

机器人 linearization、EKF、Gauss-Newton 全部依赖:

$$\delta$$

足够小。

如果 step 大, 不能只说 “nonlinear model 不好”, 而要知道被忽略的:

$$O(\|\delta\|^2)$$

已经不小。

1.4 Conditional Gaussian 具体怎么算

Joint Gaussian:

$$\begin{bmatrix} x \\ y \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} \right).$$

Condition:

$$\mathbb{E}[x | y] = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

$$\text{Cov}(x | y) = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}.$$

Scalar example:

$$\text{Var}(x) = 4, \quad \text{Var}(y) = 9, \quad \text{Cov}(x, y) = 3.$$

Observe:

$$y - \mu_y = 6.$$

Mean correction:

$$3/9 \times 6 = 2.$$

Posterior variance:

$$4 - \frac{3^2}{9} = 3.$$

Measurement 让 uncertainty 从 4 降到 3。

Kalman update 就是这个 Gaussian conditioning 结构在动态系统中的递推版本。

1.5 Scalar Kalman filter 一次完整数字算例

Prior:

$$x^- = 10, \quad P^- = 4.$$

Measurement:

$$y = 12, \quad R = 1.$$

$$H = 1.$$

Innovation:

$$r = y - x^- = 2.$$

Innovation variance:

$$S = P^- + R = 5.$$

Kalman gain:

$$K = P^- / S = 4/5 = 0.8.$$

Posterior mean:

$$x^+ = 10 + 0.8 \times 2 = 11.6.$$

Posterior variance:

$$P^+ = (1 - K)P^- = 0.2 \times 4 = 0.8.$$

为什么结果更靠近 measurement? 因为:

$$R < P^-,$$

measurement 更可信。

1.6 Allan variance: 为什么传感器 noise 不能只报一个标准差

给 discrete samples:

$$x_1, \dots, x_N$$

sampling period:

$$\tau_0.$$

选择 averaging time:

$$\tau = m\tau_0.$$

把数据分成长度 m 的 blocks, 第 k 个 block average:

$$\bar{x}_k(\tau) = \frac{1}{m} \sum_{i=km}^{(k+1)m-1} x_i.$$

Allan variance:

$$\sigma_A^2(\tau) = \frac{1}{2} \mathbb{E}[(\bar{x}_{k+1}(\tau) - \bar{x}_k(\tau))^2].$$

为什么比较相邻 block averages?

它会抑制常值 offset, 同时暴露不同时间尺度的 drift/noise。

White noise: averaging 更久会下降。

Random walk / drift: 长时间尺度反而上升。

因此画:

$$\log \sigma_A(\tau) \text{ vs } \log \tau$$

的 slope 可以区分不同 stochastic process。

这就是 Volume I 里 “IMU noise 不是一个 σ 就能描述” 的完整最小数学台阶。

Checkpoint

Volume I 应掌握: 正规方程为什么数值危险; 线性化误差来自哪一阶; Gaussian conditioning 如何变成 Kalman; Allan variance 为什么能区分时间尺度。

第二章 Volume II 补课桥：递归动力学、Contact Complementarity、Operational Inertia 与 Riccati

2.1 RNEA 不应该只记成一个函数名

Inverse dynamics: 给:

$$q, \dot{q}, \ddot{q}$$

求:

$$\tau.$$

对 serial chain, RNEA 有两个 pass。

Forward pass: 从 base 到末端计算每个 link:

angular velocity;

linear acceleration;

CoM acceleration。

Backward pass: 从末端回 base 累加:

inertial force;

$$f_i = m_i a_{C_i};$$

inertial moment;

$$n_i = I_i \dot{\omega}_i + \omega_i \times I_i \omega_i;$$

child reaction。

最后 joint torque:

$$\tau_i = S_i^\top F_i.$$

为什么是递归? 因为每个 link 只和 parent/children 局部连接。

这就是 $O(n)$ 的来源。

2.2 ABA 与“先算完整 M^{-1} ”的区别

Forward dynamics:

$$M(q)\ddot{q} + h = \tau.$$

直接：形成 M ；factorize；solve。

ABA 利用 articulated-body inertia 递归消去子树，直接求：

$$\ddot{q}$$

而不显式构造完整 dense M 。

对大 tree robot，这个结构非常重要。

本科阶段不必背 Featherstone 所有符号，但要理解：

rigid-body algorithms exploit tree sparsity.

2.3 一个 1D unilateral contact 的 complementarity 数字例子

质点高度：

$$z \geq 0.$$

地面 normal force:

$$\lambda \geq 0.$$

Complementarity:

$$z\lambda = 0.$$

Case A:

$$z = 0.1 > 0.$$

则：

$$\lambda = 0.$$

Case B:

$$\lambda = 100 > 0.$$

则：

$$z = 0.$$

不允许：

$$z > 0, \lambda > 0$$

因为物体悬空时地面不能施力。

也不允许：

$$z < 0$$

因为 penetration。

这个最小例子就是 contact-implicit optimization 里的非光滑结构。

2.4 Operational inertia 的一维例子

假设一个 2-joint robot 在某 task direction 的 Jacobian:

$$J = \begin{bmatrix} 1 & 1 \end{bmatrix}.$$

Mass matrix:

$$M = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

则:

$$M^{-1} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$JM^{-1}J^\top = 1/4 + 1 = 1.25.$$

所以:

$$\Lambda = (1.25)^{-1} = 0.8.$$

Task-space 看起来像:

$$F = 0.8 \ddot{x}$$

在这个方向上。

如果第二关节变得更重:

$$M_{22} = 9,$$

则:

$$JM^{-1}J^\top = 1/4 + 1/9 \approx 0.361,$$

$$\Lambda \approx 2.77.$$

同一 Cartesian direction 变得 “更重”。

2.5 Riccati recursion 从 finite-horizon dynamic programming 推

Linear:

$$x_{k+1} = Ax_k + Bu_k.$$

Cost:

$$J = x_N^\top P_N x_N + \sum_{k=0}^{N-1} (x_k^\top Q x_k + u_k^\top R u_k).$$

假设：

$$V_{k+1}(x) = x^\top P_{k+1} x.$$

Bellman：

$$V_k(x) = \min_u [x^\top Q x + u^\top R u + (Ax + Bu)^\top P_{k+1} (Ax + Bu)].$$

对 u 求导：

$$2Ru + 2B^\top P_{k+1} (Ax + Bu) = 0.$$

所以：

$$u = -K_k x,$$

$$K_k = (R + B^\top P_{k+1} B)^{-1} B^\top P_{k+1} A.$$

再代回得到：

$$P_k = Q + A^\top P_{k+1} A - A^\top P_{k+1} B (R + B^\top P_{k+1} B)^{-1} B^\top P_{k+1} A.$$

这就是 Riccati recursion。

MPC 加入 inequalities 后不再有简单 closed form，但 LQR 仍是它的局部核心。

Checkpoint

Volume II 应掌握：递归动力学为什么利用 tree；unilateral contact 为何需要 complementarity； Λ 是 task-space effective inertia；Riccati 来自 Bellman，而不是凭空公式。

第三章 Volume III 补课桥：Force Closure、BC Distribution Shift、DDPM Posterior 与 Flow Transport

3.1 2D force closure 的一个可画出来例子

平面 object wrench:

$$w = [f_x, f_y, \tau_z]^\top.$$

每个 friction cone 离散成两条 edge rays。

假设总 primitive wrenches:

$$w_1, \dots, w_M.$$

若存在:

$$\alpha_i > 0, \quad \sum_i \alpha_i = 1$$

使:

$$\boxed{\sum_i \alpha_i w_i = 0,}$$

且 primitive wrenches span 整个 3D planar wrench space, 则原点位于 convex hull 内部, 是 force closure 的一个常用判据。

为什么必须 positive coefficients? 因为每条 friction edge 只能“推”, 不能沿相反方向任意拉。

所以 force closure 不是:

$$\text{rank}(G) = 3$$

这么简单; 还必须满足 unilateral/friction sign constraints。

3.2 一个简单 LP 形式

给 primitive matrix:

$$W = \begin{bmatrix} w_1 & \cdots & w_M \end{bmatrix}.$$

求:

$$\alpha.$$

约束:

$$W\alpha = 0,$$

$$\mathbf{1}^\top \alpha = 1,$$

$$\alpha_i \geq \epsilon > 0.$$

若有可行解并满足 full-dimensional span, 说明原点有严格 interior representation 的证据。

这是把“抓稳”变成 convex feasibility 的最小计算版本。

3.3 BC compounding error 的两步 toy example

Expert states:

$$s_0 \rightarrow s_1 \rightarrow s_2.$$

Policy 在每个 expert state 有:

$$P(\text{wrong action}) = \epsilon.$$

Step 0 错误概率:

$$\epsilon.$$

如果错后进入 OOD state, 假设后续几乎必错。

那么 step 1 错误概率至少:

$$P(\text{step0 wrong}) + P(\text{step0 correct, step1 wrong})$$

$$= \epsilon + (1 - \epsilon)\epsilon = 2\epsilon - \epsilon^2 \approx 2\epsilon.$$

累计错误:

$$\approx 3\epsilon$$

在仅两步后的 toy setting 就已经高于 iid 的 2ϵ 直觉。

更长 horizon 会因 state distribution 改变产生更严重累积。

DAgger 的核心就是把这些 policy-visited states 加入监督。

3.4 DDPM posterior 为什么仍是 Gaussian

Forward:

$$q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, \beta_t I).$$

Closed form:

$$q(x_{t-1}|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}x_0, (1 - \bar{\alpha}_{t-1})I).$$

由 Bayes:

$$q(x_{t-1}|x_t, x_0) \propto q(x_t|x_{t-1})q(x_{t-1}|x_0).$$

两个关于 x_{t-1} 的 Gaussian 相乘仍是 Gaussian。

结果:

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}(\tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I).$$

其中:

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t.$$

为什么 network 可只预测 noise? 因为 x_0 可由:

$$x_t, \epsilon$$

重建, 因此 $\tilde{\mu}_t$ 也能由 noise prediction parameterize。

这就是 Volume III Diffusion Policy chapter 应补齐的中间概率台阶。

3.5 DDPM ELBO 与 simplified noise loss 的关系

Generative likelihood:

$$p_\theta(x_0) = \int p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t) dx_{1:T}.$$

Variational bound 把 negative log likelihood 分成若干 KL:

$$D_{\text{KL}}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t)).$$

当 reverse variance 固定, 优化 Gaussian mean 的 KL 等价于带 timestep weight 的:

$$\|\epsilon - \epsilon_\theta(x_t, t)\|^2.$$

实践中的 simplified objective 通常忽略/改变精确权重, 换取更稳定训练。

所以 “noise MSE” 不是经验魔法, 而是 variational likelihood 的简化 parameterization。

3.6 Flow Matching continuity equation 从守恒直觉来

考虑一维 probability density $p(x, t)$ 。

某小区间:

$$[a, b].$$

里面 probability mass:

$$M(t) = \int_a^b p(x, t) dx.$$

若 particle velocity:

$$v(x, t),$$

左边流入:

$$p(a, t)v(a, t),$$

右边流出:

$$p(b, t)v(b, t).$$

所以:

$$\frac{dM}{dt} = p(a)v(a) - p(b)v(b).$$

另一方面:

$$\frac{dM}{dt} = \int_a^b \frac{\partial p}{\partial t} dx.$$

用 fundamental theorem:

$$p(a)v(a) - p(b)v(b) = - \int_a^b \frac{\partial(pv)}{\partial x} dx.$$

由于区间任意:

$$\boxed{\frac{\partial p}{\partial t} + \frac{\partial(pv)}{\partial x} = 0.}$$

多维:

$$\boxed{\partial_t p + \nabla \cdot (pv) = 0.}$$

这就是 Flow Matching 里 “velocity field transport probability” 最基础的来源。

3.7 为什么 linear CFM target 是 $x_1 - x_0$

定义 path:

$$x_t = (1 - t)x_0 + tx_1.$$

直接求导:

$$\boxed{\dot{x}_t = x_1 - x_0.}$$

所以当训练样本由: base sample x_0 ; data action x_1 ; 随机 t ; 构成 x_t , 网络回归:

$$v_{\theta}(x_t, t, c) \approx x_1 - x_0.$$

关键难点不是这一步导数, 而是: 不同 pairings 共同形成 marginal probability path; 好的 coupling/path 会让 velocity field 更简单。

Checkpoint

Volume III 应掌握: force closure 不仅是 rank, 还需要 unilateral positive cone; BC shift 来自 policy 改变未来输入; DDPM noise loss 有 posterior/ELBO 来源; Flow Matching velocity field 受 continuity equation 约束。

第四章 全文继续修订时必须遵守的写作规则

以后正式 1.1 重排时，每个关键主题至少满足：

先给一维/二维数值例子；

再给一般矩阵公式；

再给假设；

再给失败反例；

再给代码；

最后才进入论文架构。

任何出现以下句式都要警惕：

“容易得到”；

“显然”；

“类似可得”；

“省略推导”；

“由经典结果”。

如果结果对后续章节关键，就应把中间步骤写出来。

本科生不应该因为“没上过研究生机器人课”而无法读这套书；真正允许默认的只有本科微积分、线代、概率与基础 Python。